

Nama :Andreas Hasiholan Sinaga

NIM : 1103213033

### Regression Model: MLP Regression

	fixed acidity	volatile acidity	citric acid	residual sugar \
count	4898.000000	4898.000000	4898.000000	4898.000000
mean	6.854788	0.278241	0.334192	6.391415
std	0.843868	0.100795	0.121020	5.072058
min	3.800000	0.080000	0.000000	0.600000
25%	6.300000	0.210000	0.270000	1.700000
50%	6.800000	0.260000	0.320000	5.200000
75%	7.300000	0.320000	0.390000	9.900000
max	14.200000	1.100000	1.660000	65.800000

  

	chlorides	free sulfur dioxide	total sulfur dioxide	density \
count	4898.000000	4898.000000	4898.000000	4898.000000
mean	0.045772	35.308085	138.360657	0.994027
std	0.021848	17.007137	42.498065	0.002991
min	0.009000	2.000000	9.000000	0.987110
25%	0.036000	23.000000	108.000000	0.991723
50%	0.043000	34.000000	134.000000	0.993740
75%	0.050000	46.000000	167.000000	0.996100
max	0.346000	289.000000	440.000000	1.038980

  

	pH	sulphates	alcohol	quality
count	4898.000000	4898.000000	4898.000000	4898.000000
mean	3.188267	0.489847	10.514267	5.877909
std	0.151001	0.114126	1.230621	0.885639
min	2.720000	0.220000	8.000000	3.000000
25%	3.090000	0.410000	9.500000	5.000000
50%	3.180000	0.470000	10.400000	6.000000
75%	3.280000	0.550000	11.400000	6.000000
max	3.820000	1.080000	14.200000	9.000000

Dataset wine quality memuat 4.898 sampel dengan berbagai parameter fisik dan kimiawi yang digunakan untuk menentukan kualitas wine. Parameter fixed acidity memiliki nilai rata-rata 6,85 dengan kisaran antara 4,6 hingga 14,2, menunjukkan kadar asam stabil yang dominan. Sementara itu, volatile acidity rata-rata sebesar 0,278 dengan rentang 0,08 hingga 1,10, di mana nilai tinggi dapat memengaruhi rasa wine. Kandungan citric acid rata-rata adalah 0,334 dengan kisaran 0 hingga 1,66, yang berperan sebagai pengawet alami. Residual sugar, yang menunjukkan sisa gula setelah fermentasi, memiliki nilai rata-rata 6,39 dengan rentang cukup lebar, yaitu 0,6 hingga 65,8, yang dapat memengaruhi rasa manis wine.

Kandungan chlorides rata-rata sebesar 0,045 dengan kisaran 0,009 hingga 0,346, mencerminkan kadar garam dalam wine. Free sulfur dioxide, yang digunakan untuk mencegah oksidasi, memiliki rata-rata 35,3 dengan rentang 2 hingga 289, sedangkan total sulfur dioxide memiliki rata-rata 138,36 dengan kisaran 9 hingga 440. Parameter density, yang berkaitan dengan kadar gula dan alkohol, memiliki rata-rata 0,994 dengan rentang 0,987 hingga 1,038. Tingkat keasaman wine diukur dengan pH, yang rata-rata sebesar 3,19 dengan kisaran 2,72 hingga 3,82.

Selain itu, kandungan sulphates, yang berfungsi sebagai antiseptik dan penambah rasa, memiliki nilai rata-rata 0,489 dengan kisaran 0,22 hingga 1,08. Kandungan alcohol

dalam wine rata-rata sebesar 10,51% dengan rentang 8% hingga 14%. Parameter terakhir adalah quality, yang merepresentasikan penilaian kualitas wine dengan rata-rata skor 5,88 dan rentang antara 3 hingga 9. Informasi ini memberikan gambaran distribusi data serta dapat digunakan untuk analisis lebih lanjut dalam menentukan karakteristik wine berkualitas.

```

1 # Langkah 5: Loop Hiperparameter
2 results = []
3 hyperparameters = {
4     'hidden_layers': [[4], [8], [16], [32], [64], [4, 8], [8, 16], [32, 64], [16, 32, 64]],
5     'activation_fn': ['linear', 'sigmoid', 'relu', 'softmax', 'tanh'],
6     'learning_rate': [10, 1, 0.1, 0.01, 0.001],
7     'batch_size': [16, 32, 64, 128, 256],
8     'epochs': [1, 10, 25, 50, 100, 250]
9 }
10

```

Parameter-parameter yang akan dieksplorasi didefinisikan dalam sebuah dictionary bernama hyperparameters. Hyperparameter yang akan diuji meliputi jumlah dan konfigurasi hidden\_layers dengan berbagai kombinasi seperti [4], [8], [16], [32], dan [64], serta konfigurasi lebih kompleks seperti [4, 8], [8, 16], dan seterusnya. Selain itu, fungsi aktivasi (activation\_fn) juga dieksplorasi menggunakan pilihan seperti 'linear', 'sigmoid', 'relu', 'softmax', dan 'tanh'. Kecepatan pembelajaran (learning\_rate) juga diuji dengan beberapa nilai seperti 10, 1, 0.1, 0.01, dan 0.001, untuk memastikan bahwa model mendapatkan pembaruan bobot yang optimal. Selain itu, ukuran batch (batch\_size) dieksplorasi dalam kisaran 16, 32, 64, 128, dan 256, yang menentukan jumlah sampel yang diproses sebelum memperbarui bobot model. Akhirnya, jumlah epoch pelatihan (epochs) diuji dalam beberapa nilai seperti 1, 10, 25, 50, 100, dan 250, untuk memastikan bahwa model mencapai konvergensi. Kombinasi hyperparameter ini nantinya akan digunakan dalam loop eksperimen untuk melatih model, mengevaluasi kinerjanya, dan menyimpan hasilnya di dalam list results. Penyiapan ini bertujuan untuk menemukan konfigurasi hyperparameter terbaik yang menghasilkan performa optimal pada tugas regresi.

```

[10] 0.05
...
10 kombinasi hyperparameter terbaik berdasarkan loss:
  hidden_layers activation_fn learning_rate batch_size epochs loss \
5492 [32, 64] sigmoid 0.010 16 25 0.477159
5493 [32, 64] sigmoid 0.010 16 50 0.479223
6411 [16, 32, 64] relu 0.010 128 50 0.479764
6392 [16, 32, 64] relu 0.010 16 25 0.480947
5699 [32, 64] relu 0.001 256 250 0.481570
3275 [64] sigmoid 0.001 16 250 0.481592
4157 [4, 8] relu 0.010 64 250 0.481774
6692 [16, 32, 64] tanh 0.010 16 25 0.482184
3423 [64] relu 0.001 16 50 0.482485
3443 [64] relu 0.001 128 250 0.483584

  mae
5492 0.539199
5493 0.542257
6411 0.546583
6392 0.547372
5699 0.542964
3275 0.543475
4157 0.550002
6692 0.553084
3423 0.545185
3443 0.543536

```

Kecepatan pembelajaran (`learning_rate`) yang optimal dalam kombinasi terbaik sebagian besar berada di nilai 0.01, diikuti oleh 0.001. Hal ini menunjukkan bahwa nilai tersebut cukup efektif untuk memperbarui bobot model secara stabil dan efisien. Ukuran batch (`batch_size`) yang memberikan hasil terbaik bervariasi dari 16 hingga 256, dengan batch kecil seperti 16 sering memberikan hasil yang baik karena pembaruan bobot yang lebih sering dapat membantu model mencapai konvergensi lebih cepat. Adapun jumlah epoch yang diuji pada kombinasi terbaik berkisar dari 25 hingga 250, tetapi konfigurasi dengan jumlah epoch kecil seperti 25 sering muncul dalam kombinasi terbaik, yang menunjukkan bahwa model dapat mencapai performa optimal tanpa memerlukan iterasi yang berlebihan.

The graph illustrates the relationship between the number of epochs and the loss for various hidden layer configurations. The y-axis represents the loss, scaled by  $10^{15}$ , and the x-axis represents the number of epochs from 0 to 250. The legend identifies the configurations: [4], [8], [16], [32], [64], [4, 8], [8, 16], [32, 64], and [16, 32, 64]. The [16, 32, 64] configuration shows a significant initial loss of  $2 \times 10^{15}$  at epoch 0, which drops sharply to near zero by epoch 10 and remains stable. Other configurations maintain a loss near zero throughout the training process.

Epochs	[4]	[8]	[16]	[32]	[64]	[4, 8]	[8, 16]	[32, 64]	[16, 32, 64]
0	0	0	0	0	0	0	0	0	$2 \times 10^{15}$
10	0	0	0	0	0	0	0	0	$0 \times 10^{15}$
50	0	0	0	0	0	0	0	0	$0.1 \times 10^{15}$
100	0	0	0	0	0	0	0	0	$0 \times 10^{15}$
250	0	0	0	0	0	0	0	0	$0.2 \times 10^{15}$

Grafik tersebut menunjukkan hubungan antara jumlah epoch dan nilai loss berdasarkan berbagai konfigurasi hidden layers pada model Multi-Layer Perceptron (MLP) untuk tugas regresi. Pada awal pelatihan (epoch rendah), nilai loss cenderung sangat tinggi, terutama untuk konfigurasi hidden layers yang lebih kompleks seperti [16, 32, 64]. Namun, nilai loss menurun tajam dalam beberapa epoch pertama, menunjukkan pembelajaran signifikan di tahap awal. Setelah itu, sebagian besar konfigurasi hidden layers mencapai stabilitas dengan nilai loss yang rendah, menandakan bahwa model telah mencapai konvergensi. Konfigurasi sederhana seperti [4] dan [8] cenderung mencapai nilai loss rendah lebih cepat, sementara konfigurasi yang lebih kompleks tetap kompetitif setelah stabil.